Propuesta de Proyecto y Cronograma Exprés: SIPA-INE

Sistema de Identificación Predictiva de Abstencionismo y Simulación de Impacto Territorial (con XGBoost)

Reto 2: Predicción y escenarios de riesgo de abstención

Tipo de reto: Analítica predictiva con Machine Learning (sin datos personales)
Pregunta guía: ¿Qué zonas podrían presentar mayor abstención en el futuro si no se interviene?
Propósito: Planeación anticipada, priorización estratégica de recursos y simulación de escenarios para el Instituto Nacional Electoral (INE).

---

1. Objetivo General y Enfoque Tecnológico

Diseñar e implementar un modelo predictivo basado en **XGBoost (Extreme Gradient Boosting)** utilizando datos tabulares agregados y disociados (a nivel de sección electoral o municipio). El sistema permite mapear el riesgo futuro de abstencionismo, simular escenarios de intervención ("What-If") y priorizar geográficamente los recursos institucionales.

---

2. Metodología Técnica con XGBoost

Paso 1: Ingeniería de Características (Features) y Datos Agregados

- **Variables Históricas (INE):** Porcentajes de participación y abstención en elecciones pasadas a nivel sección.
- **Variables Sociodemográficas (INEGI):** Edad promedio, porcentaje de población joven (18-29 años), grado promedio de escolaridad, tasa de actividad económica e índice de marginación.
- **Variables Operativas:** Distancia o densidad de casillas y Módulos de Atención Ciudadana (MAC).

Paso 2: Modelo Predictivo con XGBoost

Se entrena un modelo de Machine Learning supervisado (`XGBRegressor` o `XGBClassifier`) para capturar relaciones no lineales complejas entre el perfil sociodemográfico de una zona y su propensión al abstencionismo.

- **Feature Importance:** Permite identificar con rigor analítico cuáles son los factores determinantes de la abstención en cada región.

Paso 3: Motor de Simulación de Escenarios

- **Escenario A (Sin Intervención / Inercial):** Proyección con tendencias actuales para identificar el crecimiento natural del abstencionismo.
- **Escenario B (Con Intervención Focalizada):** Modificación algorítmica de variables controlables (ej. optimización de módulos o campañas digitales focalizadas) para medir la reducción estimada del riesgo.

---

3. Cronograma de Implementación (Viabilidad a 2 Semanas)

El proyecto está diseñado para desarrollarse de forma ágil en un plazo de **14 días**:

Semana 1: Datos, Ingeniería de Variables y Entrenamiento

- **Días 1 - 2 (Recolección y Limpieza):** Integración de bases de datos públicas del INE e INEGI a nivel territorial y disociado.
- **Días 3 - 4 (Preparación de Variables):** Construcción de la tabla maestra con históricos, demografía y marginación.
- **Días 5 - 7 (Entrenamiento con XGBoost):** Scripting en Python (`xgboost`, `pandas`, `scikit-learn`), entrenamiento inicial y validación de métricas de error (RMSE).

Semana 2: Simulación, Visualización y Presentación

- **Días 8 - 9 (Motor de Escenarios):** Programación de las simulaciones "What-If" (Escenario A vs. Escenario B).
- **Días 10 - 11 (Visualización Territorial):** Generación de mapas de calor interactivos (utilizando herramientas como `Folium` o `Streamlit`) clasificados por niveles de riesgo (Muy Alto, Alto, Medio, Bajo).
- **Días 12 - 14 (Documentación y Cierre):** Elaboración del reporte técnico final, síntesis ejecutiva y preparación del pitch de presentación para el INE.

---

4. Entregables del Proyecto

1. **Modelo Predictivo Operativo:** Script en Python con XGBoost y pipeline de simulación de escenarios.
2. **Tablero / Mapa de Calor de Riesgo Territorial:** Visualización clara de las secciones prioritarias en color rojo (riesgo muy alto).
3. **Documento Técnico y Metodológico:** Justificación analítica del uso de datos agregados y recomendaciones estratégicas para la toma de decisiones del INE.